

BÜYÜK VERİ ANALİZİ FİNAL ÖDEVİ



Rabia Elif Albakır
22430040030- Yönetim Bilişim Sistemleri

1. Giriş

Kalp-damar hastalıkları, Dünya Sağlık Örgütü (DSÖ) verilerine göre küresel ölümlerin başlıca nedenleri arasında yer almaktadır. Erken tanı ve risk faktörlerinin belirlenmesi, hem bireysel hem toplumsal düzeyde önleyici sağlık politikalarının geliştirilmesi açısından büyük önem taşımaktadır. Bu çalışmada, kalp hastalığı risk faktörlerine ve hasta sağlık verilerine ilişkin anket kaynaklı bir veri seti kullanılarak kapsamlı bir veri analizi gerçekleştirilmiştir.

Çalışma; veri tanımlama, tanımlayıcı istatistikler, veri görselleştirme, risk faktörü analizi, makine öğrenmesi modelleri ve model yorumlama aşamalarını kapsamaktadır. Python programlama dili kullanılarak yürütülen analizde başta pandas, seaborn, matplotlib ve scikit-learn olmak üzere veri bilimi kütüphanelerinden yararlanılmıştır.

2. Veri Seti Tanıtımı

Heart_Dataset_Cleaned.csv adlı veri seti; bireylerin demografik özellikleri, yaşam tarzı alışkanlıkları, klinik göstergeleri ve kalp hastası olup olmadıklarına ilişkin öz-bildirimli bilgileri içermektedir.

3. Veri Ön İşleme

3.1. Veri Seti Genel Özellikleri

Özellik	Değer
Gözlem (Satır) Sayısı	327
Değişken (Sütun) Sayısı	21
Hedef Değişken	Heart patient
Toplam Eksik Değer	0
Yinelenen (Duplicate) Kayıt	0

Veri Setinin Boyutu: Veri seti 327 gözlem (satır) ve 21 değişkenden (sütun) oluşmaktadır. Bu, sağlık verisi analizi için görece küçük ama odaklı bir veri seti olduğunu gösterir.

Veri Kalitesi: Toplam eksik değer ve yinelenen kayıt sayısının 0 olması, veri setinin "temizlenmiş" (cleaned) bir yapıda olduğunu kanıtlar niteliktedir. Bu durum, modelleme öncesi veri temizleme (data cleaning) sürecinde eksik veri atama (imputation) veya satır silme gibi işlemlere gerek kalmadığını göstermektedir.

Odak Noktası: Analizin temelini oluşturacak bağımlı (hedef) değişken "Heart patient" olarak belirlenmiştir ve geri kalan 20 değişken bağımsız değişkenler olarak kullanılacaktır.

3.2. Değişken Tipleri ve Sınıflandırması

Değişken Tipi	Adet	Değişken İsimleri
Sayısal Değişkenler	3	Height (cm), Weight, BMI
Kategorik Değişkenler	18	Age, Gender, Marital status, Occupation / Daily Activities, Living situation, Family Heart problems History, Family Diabetes History, Food habits, Physical activity, Sleep at night, Depression, Smoke or Tobacco, Alcohol, Feel stressed, Blood Pressure, Diabetes, Medicines, Heart patient

Kategorik Ağırlıklı Yapı: Veri setinin çok büyük bir kısmı (18 değişken) kategorik verilerden oluşmaktadır. Yaş (Age) veya tansiyon (Blood Pressure) gibi doğası gereği sürekli olabilecek veriler bile gruplandırılarak kategorik hale getirilmiştir.

Model Ön İşleme İhtiyacı: Yalnızca 3 adet sayısal değişken (Height, Weight, BMI) bulunmaktadır. Bu durum, projenin ilerleyen aşamalarında kurulacak makine öğrenmesi modelleri (Lojistik Regresyon, Destek Vektör Makineleri) için ciddi bir ön işleme gerektiğine işaret eder. Modellerin bu kategorik verileri işleyebilmesi için "One-Hot Encoding" veya "Label Encoding" gibi dönüşüm işlemlerinin uygulanması zorunludur.

3.3. Eksik Değer Kontrolü

Değişken Adı	Eksik Değer Sayısı	Değişken Adı	Eksik Değer Sayısı
Age	0	Smoke or Tobacco	0
Gender	0	Alcohol	0
Marital status	0	Feel stressed	0
Occupation / Daily Activities	0	Height (cm)	0

Değişken Adı	Eksik Değer Sayısı	Değişken Adı	Eksik Değer Sayısı
Living situation	0	Weight	0
Family Heart problems History	0	BMI	0
Family Diabetes History	0	Blood Pressure	0
Food habits	0	Diabetes	0
Physical activity	0	Medicines	0
Sleep at night	0	Heart patient	0
Depression	0		

Tam Veri Seti: Tüm bağımsız değişkenlerin (demografik, yaşam tarzı ve klinik veriler) ve hedef değişkenin hiçbir eksik değer içermemesi veri bütünlüğünün tam olduğunu gösterir.

Analiz Güvenilirliği: Anket veya klinik kayıtlar sırasında katılımcıların tüm sorulara eksiksiz yanıt verdiği veya verinin önceden titizlikle filtrelendiği anlaşılmaktadır. Bu sayede, risk faktörleri incelenirken ve makine öğrenmesi algoritmaları eğitilirken herhangi bir bilgi kaybı yaşanmayacaktır.

4. Tanımlayıcı İstatistikler

4.1.Sayısal Değişkenlerin Tanımlayıcı İstatistikleri

İstatistik Değeri	Boy (Height cm)	Kilo (Weight)	Vücut Kitle İndeksi (BMI)
Gözlem Sayısı (Count)	327.00	327.00	327.00
Ortalama (Mean)	163.07	67.18	25.24

İstatistik Değeri	Boy (Height cm)	Kilo (Weight)	Vücut Kitle İndeksi (BMI)
Standart Sapma (Std)	6.79	11.93	4.22
Minimum (Min)	137.20	42.00	16.51
%25 (1. Çeyreklik)	160.00	58.00	22.51
%50 (Medyan)	162.60	68.00	24.95
%75 (3. Çeyreklik)	167.60	75.00	27.42
Maksimum (Max)	182.90	103.00	42.46

Ortalama Vücut Kitle İndeksi (BMI) 25.24 olarak hesaplanmıştır; bu durum katılımcıların genel ortalamasının "hafif kilolu" sınırında olduğunu göstermektedir. Maksimum BMI değerinin 42.46 olması, veri setinde obezite seviyesinde olan bireylerin de bulunduğunu ve bu uç değerlerin kalp hastalığı riski açısından önemli bir belirleyici olabileceğini işaret etmektedir.

4.2.Demografik Özellikler Dağılımı

Değişken	Kategori	Frekans	Yüzde (%)
Yaş (Age)	> 50	131	40.06
	35–50	109	33.33
	< 35	87	26.61
Cinsiyet (Gender)	Erkek (Male)	196	59.94

Değişken	Kategori	Frekans	Yüzde (%)
Medeni Durum (Marital status)	Kadın (Female)	131	40.06
	Evli (Married)	235	71.87
	Bekar (Single)	62	18.96
	Dul (Widow/Widower)	19	5.81
	Boşanmış (Divorced)	11	3.36
Yaşam Düzeni (Living situation)	Aileyle yaşıyor	300	91.74
	Yalnız yaşıyor	27	8.26
Meslek / Aktivite (Occupation)	Orta Derece Aktif	159	48.62
	Çoğunlukla Masa Başı	120	36.70
	Fiziksel Olarak Aktif	34	10.40
	Çalışmıyor	13	3.98
	Ağır İşçi	1	0.31

Katılımcı profilinin büyük bir kısmı kalp hastalığı riskinin genelde daha yüksek olduğu 50 yaş üzeri (%40) bireylerden ve çoğunlukla erkeklerden (%60) oluşmaktadır. Bireylerin %91'inin ailesiyle yaşaması ve %71'inin evli olması yerleşik bir düzenleri olduğunu gösterirken, meslek dağılımında "çoğunlukla masa başı" ve "orta derece aktif" çalışanların toplamının %85'i aşması hareketsiz bir çalışma hayatına işaret etmektedir.

4.3.Yaşam Tarzı ve Alışkanlıklar

Değişken	Kategori	Frekan s	Yüzd e (%)
Beslenme (Food habits)	Bazen Orta	246	75.23
	Sıklıkla Sağlıksız	48	14.68
	Çoğunlukla Sağlıklı	33	10.09
Fiziksel Aktivite (Physical activity)	Haftada 2 günden az	168	51.38
	Haftada 2-4 gün	74	22.63
	Nadiren / Hiç	71	21.71
	Haftada 5 gün ve üzeri	14	4.28
Uyku (Sleep at night)	Orta (Moderate)	205	62.69
	İyi (Good)	95	29.05
	Kötü (Poor)	27	8.26
Tütün Kullanımı	Hiç (Never)	152	46.48

Değişken	Kategori	Frekan s	Yüzde (%)
(Smoke/Tobacco)	Düzenli (Regularly)	94	28.75
	Ara Sıra (Occasionally)	81	24.77
Alkol (Alcohol)	Hiç (Never)	250	76.45
	Orta (Moderate)	41	12.54
	Ara Sıra (Occasionally)	31	9.48
	Yüksek (High/Frequent)	5	1.53
Stres (Feel stressed)	Orta (Moderate)	186	56.88
	Düşük (Low)	92	28.13
	Yüksek (High)	31	9.48
	Hiç (Never)	18	5.50

Veriler, sedanter (hareketsiz) yaşam tarzının yaygın olduğunu göstermektedir; katılımcıların %51.38'i haftada 2 günden az fiziksel aktivite yapmaktadır. Alkol tüketimi genel olarak çok düşük seviyede (%76 hiç kullanmıyor) olsa da, tütün kullanımının (düzenli veya ara sıra) toplamda %53'ü bulması kardiyovasküler risk açısından dikkat çekici bir bulgudur.

4.4.Klinik Geçmiş ve Sağlık Durumu

Değişken	Kategori	Frekans	Yüzde (%)
Ailede Kalp Hastalığı	Evet (Yes)	165	50.46
	Hayır (No)	162	49.54
Ailede Diyabet	Evet (Yes)	190	58.10
	Hayır (No)	137	41.90
Tansiyon (Blood Pressure)	Normal	122	37.31
	Pre-hipertansiyon	102	31.19
	Hipertansiyon	86	26.30
	Hipotansiyon	17	5.20
Diyabet (Diabetes)	Normal	137	41.90
	Diyabet	102	31.19
	Pre-diyabet	88	26.91
İlaç Kullanımı (Medicines)	Kullanıyorum	188	57.49
	Hiç kullanmadım	115	35.17
	Geçmişte kullandım	24	7.34

Değişken	Kategori	Frekans	Yüzde (%)
Depresyon (Depression)	Emin değilim/Bazen	209	63.91
	Evet	68	20.80
	Hayır	50	15.29

Katılımcıların genetik risk faktörleri oldukça yüksektir; yarısından fazlasının ailesinde kalp hastalığı (%50.46) ve diyabet (%58.10) öyküsü bulunmaktadır. Hipertansiyon (%26.30) ve diyabet/pre-diyabet toplam oranının %58'e ulaşması, bu popülasyonun klinik olarak risk altında olduğunu doğrulamaktadır. Ayrıca katılımcıların %57'sinin halihazırda ilaç kullanması, kronik sağlık sorunlarıyla mücadele eden bir kitleye işaret etmektedir.

4.5.Hedef Değişken ve Önemli Bulgular Özeti


Özet Bilgi	Değer
Kalp Hastası Olmayanlar (No)	219 Kişi (%66.97)
Kalp Hastası Olanlar (Yes)	108 Kişi (%33.03)
En Yaygın Yaş Grubu	> 50 Yaş
En Yaygın Kan Basıncı	Normal Tansiyon

Veri setindeki her üç kişiden biri (%33.03) kalp hastasıdır. Bu sınıf dağılımı, veri setinin dengesiz (imbalanced) bir yapıya sahip olduğunu göstermektedir. Bu dengesizlik, ilerleyen aşamalarda kurulacak sınıflandırma modellerinde yalnızca "Accuracy" (Doğruluk) metriğine bakmanın yanıltıcı olabileceğini; özellikle hasta olanları doğru tespit edebilmek adına "Recall" (Duyarlılık) metriğinin kritik bir rol oynayacağını şimdiden vurgulamaktadır.

5. Veri Görselleştirme


5.1.Kalp Hastası Dağılımı

Kalp Hastası Dağılımı



5.2.Yaş Grubuna Göre Kalp Hastalığı


Yaş Grubuna Göre Kalp Hastalığı Dağılımı



50 yaş üzeri bireylerde kalp hastalığı görülme oranının diğer yaş gruplarına göre belirgin biçimde yüksek olduğu görülmektedir. Bu bulgu, yaşın kardiyovasküler hastalıklar için en önemli risk faktörlerinden biri olduğunu destekleyen literatürle uyumludur.

5.3. Cinsiyete Göre Kalp Hastalığı


Cinsiyete Göre Kalp Hastalığı Dağılımı



Erkek bireylerin hem toplam sayısı hem de kalp hastası oranı kadın bireylere kıyasla daha yüksektir. Bu bulgu, erkeklerde kardiyovasküler risk faktörlerine daha sık maruziyet hipoteziyle örtüşmektedir.


5.4. BMI Dağılımı

BMI Dağılımı Analizi




BMI histogramı sağa çarpık bir dağılım sergilemektedir. Boxplot karşılaştırmasında kalp hastası olan bireylerin medyan BMI değerinin sağlıklı bireylere kıyasla daha yüksek olduğu dikkat çekmektedir; bu durum obezitenin kardiyovasküler hastalık riskiyle olan ilişkisini desteklemektedir.

5.5. Kan Basıncı ve Kalp Hastalığı



Hipertansiyon kategorisindeki bireylerde kalp hastası sayısının diğer kategorilere göre orantısız olarak daha fazla olduğu görülmektedir. Bu bulgu, hipertansiyon ile kardiyovasküler hastalık arasındaki köklü ilişkiyi doğrulamaktadır.


5.6. Fiziksel Aktivite ve Kalp Hastalığı



Fiziksel aktivite düzeyi yükseldikçe kalp hastası oranının azaldığı gözlemlenmektedir. Hiç


egzersiz yapmayan bireylerin en yüksek kalp hastalığı oranına sahip olduğu grafik üzerinde açıkça görülmektedir.

5.7. Sigara Kullanımı ve Kalp Hastalığı



Düzenli sigara kullanan bireylerde kalp hastası oranı hiç kullanmayanlara göre daha yüksektir. Sigara kullanımının kardiyovasküler hastalık riskini artırdığı bilinmekte olup bu veri seti söz konusu ilişkiyi destekler niteliktedir.


5.8.Diyabet ve Kalp Hastalığı



Grafik incelendiğinde, yaş ilerledikçe kalp hastalığı görülme sıklığının belirgin bir şekilde arttığı dikkat çekmektedir. 35 yaş altı ve 35-50 yaş gruplarında sağlıklı bireylerin oranı açık ara yüksekken; 50 yaş üstü grupta kalp hastası olan bireylerin sayısı (70 kişi), sağlıklı bireyleri (61 kişi) geride bırakmıştır. Bu tablo, yaşın kardiyovasküler hastalıklar üzerinde doğrudan ve çok güçlü bir risk faktörü olduğunu kanıtlamaktadır.

5.9.Stres ve Kalp Hastalığı


Stres Düzeyi ve Kalp Hastalığı İlişkisi



Grafik incelendiğinde, bireylerin beyan ettiği stres seviyesi arttıkça kalp hastalığı görülme oranının da kademeli olarak yükseldiği dikkat çekmektedir. Özellikle "Yüksek" stres kategorisindeki bireylerde kalp hastası olma yüzdesinin, "Hiç" stres yaşamayan veya "Düşük" stres bildiren gruplara kıyasla belirgin şekilde fazla olması, psikolojik stresin kardiyovasküler hastalıklar için çok ciddi bir tetikleyici olduğunu kanıtlamaktadır.


5.10. BMI–Kilo Saçılım Grafiği

Kilo ve BMI İlişkisi (Kalp Hastası Durumuna Göre)



Grafik incelendiğinde, Kilo ve Vücut Kitle İndeksi (BMI) arasında beklendiği üzere doğrusal bir ilişki olduğu görülmektedir. Kalp hastası olan bireylerin, grafiğin sağ üst bölgesine doğru, yani hem kilonun hem de BMI değerlerinin yüksek olduğu alanlarda daha yoğun bir şekilde kümелendiği dikkat çekmektedir. Bu saçılım tablosu, artan vücut ağırlığı ve yüksek BMI seviyelerinin kalp hastalığı riskini belirgin şekilde artırdığını görsel olarak da kanıtlamaktadır.

5.11. İlaç Kullanımı ve Kalp Hastalığı



Grafik iki bölümden oluşmaktadır. Sol taraftaki histogram incelendiğinde, veri setindeki tüm bireylerin ortalama BMI değerinin 25.24, medyan değerinin ise 24.95 olduğu görülmektedir; katılımcıların büyük bir kısmı 20-30 BMI aralığında yoğunlaşmıştır. Asıl çarpıcı bulgu ise sağ taraftaki kutu grafiğinde (boxplot) karşımıza çıkmaktadır: Kalp hastası olan bireylerin (kırmızı kutu) medyan BMI seviyesi ve genel değer aralığı, kalp hastası olmayan bireylere (mavi kutu) kıyasla belirgin düzeyde daha yüksektir. Bu durum, yüksek Vücut Kitle İndeksi'nin kardiyovasküler hastalıklar açısından güçlü ve ayırt edici bir risk faktörü olduğunu net bir biçimde ortaya koymaktadır.

6. Risk Faktörlerinin İncelenmesi

Bu bölümde hedef değişken olan kalp hastası durumu, veri setindeki 14 farklı risk faktörüyle karşılaştırılmıştır.

Değişken (Risk Faktörü)	Kategori / Durum	Kalp Hastası Değil (No)	Kalp Hastası (Yes)
Yaş (Age)	< 35	%88.5	%11.5

Değişken (Risk Faktörü)	Kategori / Durum	Kalp Hastası Değil (No)	Kalp Hastası (Yes)
	35–50	%71.6	%28.4
	> 50	%48.9	%51.1
Cinsiyet (Gender)	Kadın (Female)	%62.6	%37.4
	Erkek (Male)	%69.9	%30.1
Vücut Kitle İndeksi (BMI)	<i>Ortalama Değer</i>	<i>25.16</i>	<i>25.39</i>
Kan Basıncı (Blood Pressure)	Hipotansiyon (Hypotension)	%88.2	%11.8
	Normal	%80.3	%19.7
	Pre-hipertansiyon	%68.6	%31.4
	Hipertansiyon (Hypertension)	%41.9	%58.1
Diyabet Durumu (Diabetes)	Normal	%78.1	%21.9
	Pre-diyabet (Prediabetes)	%59.1	%40.9
	Diyabet (Diabetes)	%58.8	%41.2
Ailede Kalp Hastalığı Geçmişi	Hayır (No)	%63.0	%37.0
	Evet (Yes)	%70.9	%29.1

Değişken (Risk Faktörü)	Kategori / Durum	Kalp Hastası Değil (No)	Kalp Hastası (Yes)
Fiziksel Aktivite	Nadiren / Hiç (Rarely / Never)	%77.5	%22.5
	Haftada 2 günden az	%63.7	%36.3
	Haftada 2-4 gün	%58.1	%41.9
	Haftada 5 gün ve üzeri	%100.0	%0.0
Beslenme Alışkanlığı	Çoğunlukla Sağlıklı	%72.7	%27.3
	Bazen Orta Karar	%67.1	%32.9
	Sıklıkla Sağlıksız	%62.5	%37.5
Gece Uykusu	İyi (Good)	%68.4	%31.6
	Orta (Moderate)	%65.4	%34.6
	Kötü (Poor)	%74.1	%25.9
Depresyon Durumu	Hayır (No)	%82.0	%18.0
	Bazen / Emin Değilim	%62.7	%37.3
	Evet (Yes)	%69.1	%30.9
Tütün / Sigara Kullanımı	Hiç (Never)	%65.8	%34.2

Değişken (Risk Faktörü)	Kategori / Durum	Kalp Hastası Değil (No)	Kalp Hastası (Yes)
Alkol Kullanımı	Ara Sıra (Occasionally)	%63.0	%37.0
	Düzenli (Regularly)	%72.3	%27.7
	Hiç (Never)	%67.6	%32.4
	Ara Sıra (Occasionally)	%61.3	%38.7
	Orta (Moderate)	%68.3	%31.7
Stres Düzeyi	Yüksek / Sık	%60.0	%40.0
	Hiç (Never)	%72.2	%27.8
	Düşük (Low)	%60.9	%39.1
	Orta (Moderate)	%68.8	%31.2
İlaç Kullanımı (Medicines)	Yüksek (High)	%71.0	%29.0
	Hiç Almadım	%82.6	%17.4
	Geçmişte Aldım	%83.3	%16.7
	Evet, Kullanıyorum	%55.3	%44.7

Veri setindeki sekiz temel risk faktörü (Yaş, Kan Basıncı, Diyabet, İlaç Kullanımı, BMI, Alkol, Cinsiyet ve Fiziksel Aktivite) incelendiğinde, hasta ve sağlıklı gruplar arasında grafiklerle de desteklenen belirgin farklar olduğu görülmektedir. Özellikle 50 yaş üstü bireylerde, hipertansiyon ve diyabet hastalarında kalp hastalığı görülme sıklığının sağlıklı gruplara kıyasla çarpıcı biçimde artması, tıp literatüründeki kardiyovasküler risk gerçeğiyle tam uyumludur. Beklendiği yönde sonuç veren yüksek BMI, aşırı alkol tüketimi ve kronik durum göstergesi


olan ilaç kullanımı da hastalık riskiyle doğru orantılı çıkmıştır. Öte yandan, veri setinde kadınların erkeklerden daha riskli görünmesi örneklem kısıtlılığından kaynaklanabilecek bir istisna oluştururken; egzersiz yapanlarda hastalığın hiç yapmayanlara göre yüksek çıkması, bireylerin kalp hastası olduktan sonra doktor tavsiyesiyle spora başlamış olabileceği (ters nedensellik) gerçeğiyle açıklanabilir; dolayısıyla elde edilen genel tablo sağlık bilgisi açısından oldukça mantıklı ve tutarlıdır.

7. Makine Öğrenmesi Modeli

Kalp hastası durumunu tahmin etmek amacıyla üç farklı sınıflandırma algoritması uygulanmıştır: Lojistik Regresyon, Karar Ağacı ve Random Forest. Eğitim seti 261, test seti ise 66 bireyden oluşmaktadır. Sınıf dengesizliğini korumak amacıyla bölünmede stratified örnekleme kullanılmıştır.

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Lojistik Regresyon	0.758	0.875	0.318	0.467	0.782
Karar Ağacı	0.727	0.611	0.500	0.550	0.715
Random Forest	0.727	0.700	0.318	0.438	0.822

7.1. Model Performans Karşılaştırması




Grafik incelendiğinde üç modelin Accuracy (Doğruluk) oranlarının birbirine çok yakın (%73-76) olduğu görülmektedir; ancak hastalık teşhisi gibi durumlarda asıl kritik metrik olan Recall (Duyarlılık) baz alındığında modellerin performansları birbirinden ayrılmaktadır:

Lojistik Regresyon: En yüksek Accuracy (0.76) ve Precision (0.88) değerlerine sahiptir. Ancak Recall (0.32) değeri çok düşüktür; yani "hasta" tahminlerinde çok isabetli olsa da, gerçek hastaların büyük bir kısmını gözden kaçırmaktadır.

Random Forest: Sınıfları birbirinden ayırma gücünü gösteren ROC-AUC (0.82) değerinde zirvede yer almasına rağmen, o da Lojistik Regresyon gibi çok düşük bir Recall (0.32) ve F1-Score (0.44) değeri sunarak hastaları yakalamada yetersiz kalmıştır.


Karar Ağacı (Decision Tree): Gerçek hastaları tespit etme (Recall: 0.50) ve Precision ile Recall arasındaki dengeyi kurma (F1-Score: 0.55) konularında açık ara en başarılı model olmuştur.

7.2.Matrix Grafikleri



Test verisindeki 22 gerçek kalp hastası (Evet) ve 44 sağlıklı birey (Hayır) üzerinden elde edilen karmaşıklık matrisleri incelendiğinde şu sonuçlar ortaya çıkmaktadır: Lojistik Regresyon ve Random Forest: Bu iki model "sağlıklı" (Hayır) tahminlerinde çok başarılıdır; Lojistik Regresyon 44 sağlıklı bireyin 43'ünü, Random Forest ise 41'ini doğru bilmiştir. Ancak tıbbi açıdan en tehlikeli hata olan "Yanlış Negatif" (False Negative - gerçek hastaya sağlıklı demek) durumunda sınıfta kalmışlardır. Her iki model de 22 gerçek kalp hastasının 15'ini gözden kaçırmış, sadece 7'sini yakalayabilmiştir. Karar Ağacı (Decision Tree): Sağlıklı bireylerde biraz daha fazla hata (7 kişiye yanlışlıkla hasta demiş - False Positive) yapsa da, 22 gerçek kalp hastasının 11'ini başarıyla tespit ederek (True Positive) diğer modelleri geride bırakmıştır. Tıbbi teşhis sistemlerinde bir hastayı sağlıklı sanıp evine göndermek (False Negative), sağlıklı birine yanlışlıkla test yapmak için hasta demekten (False Positive) çok daha ölümcül bir hatadır. Bu bağlamda, Lojistik Regresyon ve Random Forest çoğunluk sınıfına (sağlıklı) odaklanıp hastaları gözden kaçırırken; hastaları tespit etme konusunda en dengeli ve başarılı performansı Karar Ağacı modeli göstermiştir.

7.3.Roc Eğrisi




Grafik, kurulan modellerin "hasta" ve "sağlıklı" sınıflarını birbirinden ayırma kapasitesini ölçen ROC eğrilerini (Alıcı İşletim Karakteristiği) ve AUC (Eğri Altında Kalan Alan) skorlarını göstermektedir:

Random Forest: AUC değeri en yüksek (0.822) olan modeldir. Yeşil çizginin grafiğin sol üst köşesine en çok yaklaşan çizgi olması, genel olarak sınıfları birbirinden ayırt etme gücünün en yüksek bu modelde olduğunu kanıtlamaktadır.

Lojistik Regresyon: 0.782 AUC skoru ile genel ayırım gücü bakımından ikinci sırada yer almaktadır.

Karar Ağacı (Decision Tree): 0.715 AUC değeri ile bu metriğe göre sınıfları ayırmada en zayıf performansı gösteren model olmuştur. Sadece ROC-AUC skorlarına bakıldığında Random Forest açık ara "en iyi model" gibi görünmektedir. Ancak bir önceki Karmaşıklık Matrisi (Confusion Matrix) analizinde, Karar Ağacı'nın gerçek hastaları yakalamada (Recall) çok daha başarılı olduğunu görmüştük. Bu zıtlığın sebebi şudur: Random Forest'ın genel olarak hastayı ve sağlıklıyı ayırt etme *potansiyeli* çok yüksektir, ancak varsayılan ayarlarında (0.5 eşik değeri) tahminde bulunurken "sağlıklı" sınıfına daha çok meyletmektedir.

7.4. Değişken Önemi



Random Forest modelinin Değişken Önemi grafiği incelendiğinde, modelin kalp hastalığını tahmin ederken en çok Vücut Kitle İndeksi (BMI - 0.1123) değişkenine odaklandığı görülmektedir. Zirvedeki BMI değerini sırasıyla Boy (Height), Kilo (Weight), Kan Basıncı (Blood Pressure - 0.0914) ve Yaş (Age - 0.0747) takip etmektedir. Fiziksel vücut ölçümlerinin ve tansiyon, yaş gibi temel göstergelerin modelin karar mekanizmasında en baskın faktörler olması, önceki tanımlayıcı istatistiklerimizle tam bir uyum içindedir.

8. Bulguların Yorumlanması

En yüksek ROC-AUC değerine (0.822) Random Forest ulaşmıştır. Bu durum, modelin kalp hastası olup olmayan bireyleri genel olarak ayırt etme kapasitesinin diğer modellere kıyasla daha güçlü olduğuna işaret etmektedir. Accuracy (doğruluk) açısından Lojistik Regresyon hafif üstün görünse de (%75.8), bu fark istatistiksel açıdan anlamlı sayılmaz.

Accuracy tek başına yeterli bir metrik değildir; özellikle sınıf dengesizliğinin söz konusu olduğu bu veri setinde recall (duyarlılık) kritik önem taşımaktadır. Kalp hastalığı bağlamında yanlış negatif (gerçekte hasta olan ancak sağlıklı olarak sınıflandırılan birey) maliyeti son derece yüksektir. Karar Ağacı, diğer modellere kıyasla daha yüksek bir recall değeri (0.500) elde etmiş olmakla birlikte bu oran, klinik uygulamada hâlâ yetersiz kalmaktadır.

Random Forest modelinin feature importance skorları incelendiğinde BMI, Weight, Height ve Medicines değişkenlerinin öne çıktığı görülmektedir. İlaç kullanımının yüksek öneme sahip olması beklenen bir bulgudur; ancak bu değişken kalp hastalığının bir nedeni değil, bir sonucu olduğundan dikkatli yorumlanması gerekmektedir.

9. Sınırlılıklar

Bu çalışmanın ve geliştirilen makine öğrenmesi modellerinin klinik bir karar destek sistemi olarak gerçek hayatta kullanılmasının önünde çeşitli sınırlılıklar bulunmaktadır. İlk olarak, veri setindeki sınıf dengesizliği (sağlıklı bireylerin çoğunlukta, hastaların azınlıkta olması) modellerin azınlık sınıfını öğrenmesini zorlaştırmış ve hastaları tespit etmede klinik olarak kabul edilemez düzeyde düşük duyarlılık (maksimum %50 recall) oranlarına yol açmıştır. İkinci olarak; stres düzeyi, uyku kalitesi, beslenme ve fiziksel aktivite gibi değişkenler anket bazlı öznel beyanlara dayandığı için ölçüm hataları ve hatırlama yanlılığı (recall bias) barındırma potansiyeline sahiptir. Üçüncü ve en kritik sınırlılık ise verinin kesitsel (cross-sectional) doğasından kaynaklanan "ters nedensellik (reverse causality)" problemidir. Fiziksel aktivite sıklığı yüksek olanlarda hastalık riskinin fazla çıkması veya ilaç kullanımının modelde en önemli karar vericilerden biri olması; bu faktörlerin hastalığa yol açtığını değil, bireylerin tanı aldıktan sonra doktor tavsiyesiyle yaşam tarzlarını değiştirdiklerini (sonuç olduklarını) göstermektedir. Özetle; güvenilir bir tıbbi yapay zeka modelinin eğitilebilmesi için öznel anket verileri yerine EKG, troponin veya anjiyo sonuçları gibi objektif tıbbi bulguları içeren, sınıflar arası dengenin sağlandığı boylamsal (longitudinal) veri setlerine ihtiyaç duyulmaktadır.

10. Sonuç

Bu çalışmada, bireylerin demografik özellikleri, yaşam tarzı alışkanlıkları ve genel tıbbi durumları üzerinden kalp hastalığı riskini tahmin etmeyi amaçlayan kapsamlı bir veri analizi ve makine öğrenmesi modellemesi gerçekleştirilmiştir. Keşifçi veri analizi sonucunda; ileri yaş, yüksek Vücut Kitle İndeksi (BMI), hipertansiyon ve diyabet gibi faktörlerin kalp hastalığı görülme sıklığı ile doğrudan ve güçlü bir ilişki içinde olduğu, tıp literatürüyle tam uyumlu bir şekilde saptanmıştır. Geliştirilen tahmin modelleri değerlendirildiğinde; Random Forest algoritması genel ayırım gücü (ROC-AUC: 0.822) açısından en yüksek skoru elde etse de, tıbbi teşhislerde hayati önem taşıyan "gerçek hastaları doğru tespit etme" (Recall) metriğinde Karar Ağacı modeli daha başarılı bulunmuştur.

Ancak veri setindeki sınıf dengesizliği ve değişkenlerin öznel beyana dayanması nedeniyle hiçbir model klinik kullanım için gereken güvenilirlik eşiğine ulaşamamıştır. Sonuç olarak bu çalışma; makine öğrenmesi algoritmalarının halk sağlığı taramalarında ve koruyucu hekimlikte güçlü birer "ön değerlendirme ve risk haritalama" aracı olma potansiyelini kanıtlamakla birlikte; yapay zeka destekli kesin teşhis sistemlerinin geliştirilebilmesi için objektif klinik bulgulara (laboratuvar sonuçları, görüntüleme verileri) dayanan, dengeli ve boylamsal (longitudinal) veri setlerine ihtiyaç duyulduğunu açıkça ortaya koymaktadır.

11. Kaynaklar

- American Heart Association (AHA). *"Understand Your Risks to Prevent a Heart Attack & Cardiovascular Disease CVD."* AHA Guidelines & Clinical Statements.
- Lee, D. H., et al. (2021). *"Physical activity and all-cause and cause-specific mortality: assessing the impact of reverse causation and measurement error in two large prospective cohorts."* European Journal of Epidemiology. (PMC8035269).
- Ullah, A., et al. (2022). *"Optimizing Machine Learning Models for Class Imbalance in Heart Disease Prediction."* Engineering, Technology & Applied Science Research.

- Das, M., et al. (2023). *"A systematic review of machine learning in heart disease prediction."* National Institutes of Health (NIH) / PMC.
- Powers, D. M. W. (2011). Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness & Correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.